Prédiction de la Consommation Énergétique - Seattle

Utopios® Tous droits réservés

Contexte du Projet

Objectif : Prédire la consommation énergétique des bâtiments de Seattle

Données : Dataset Building Energy Benchmarking 2016

- Variables architecturales (surface, étages, âge)
- Types d'usage (bureaux, entrepôts, commerces)
- Localisation

Problématique : Optimiser l'efficacité énergétique et identifier les facteurs clés de consommation

Utopios® Tous droits réservés

Préparation des Données

- **Nettoyage et Preprocessing** :
  - **Prévention des fuites** : Suppression des variables contenant directement la réponse (EUI, kBtu, ENERGYSTARScore)
  - **Valeurs aberrantes** : Bornage au 1er %
  - **Variables catégorielles** : Regroupement des modalités rares (<0.5%) en "Other"
  - **Transformation logarithmique** : Application sur la cible pour améliorer la distribution

Utopios® Tous droits réservés

Métriques d'évaluation des modèles

- **RMSE** : racine de l'erreur quadratique moyenne. Pénalise fortement les grandes erreurs. Plus petit = meilleur.
- **MAE** : erreur absolue moyenne. Plus lisible, moins sensible aux valeurs extrêmes que le RMSE.
- **R^2** : part de variance expliquée par le modèle (0 à 1, peut être négatif). Plus proche de 1 = meilleur.
- **CV** : dispersion relative ((\sigma / \mu)). Permet de comparer des données avec des échelles différentes.

Utopios® Tous droits réservés

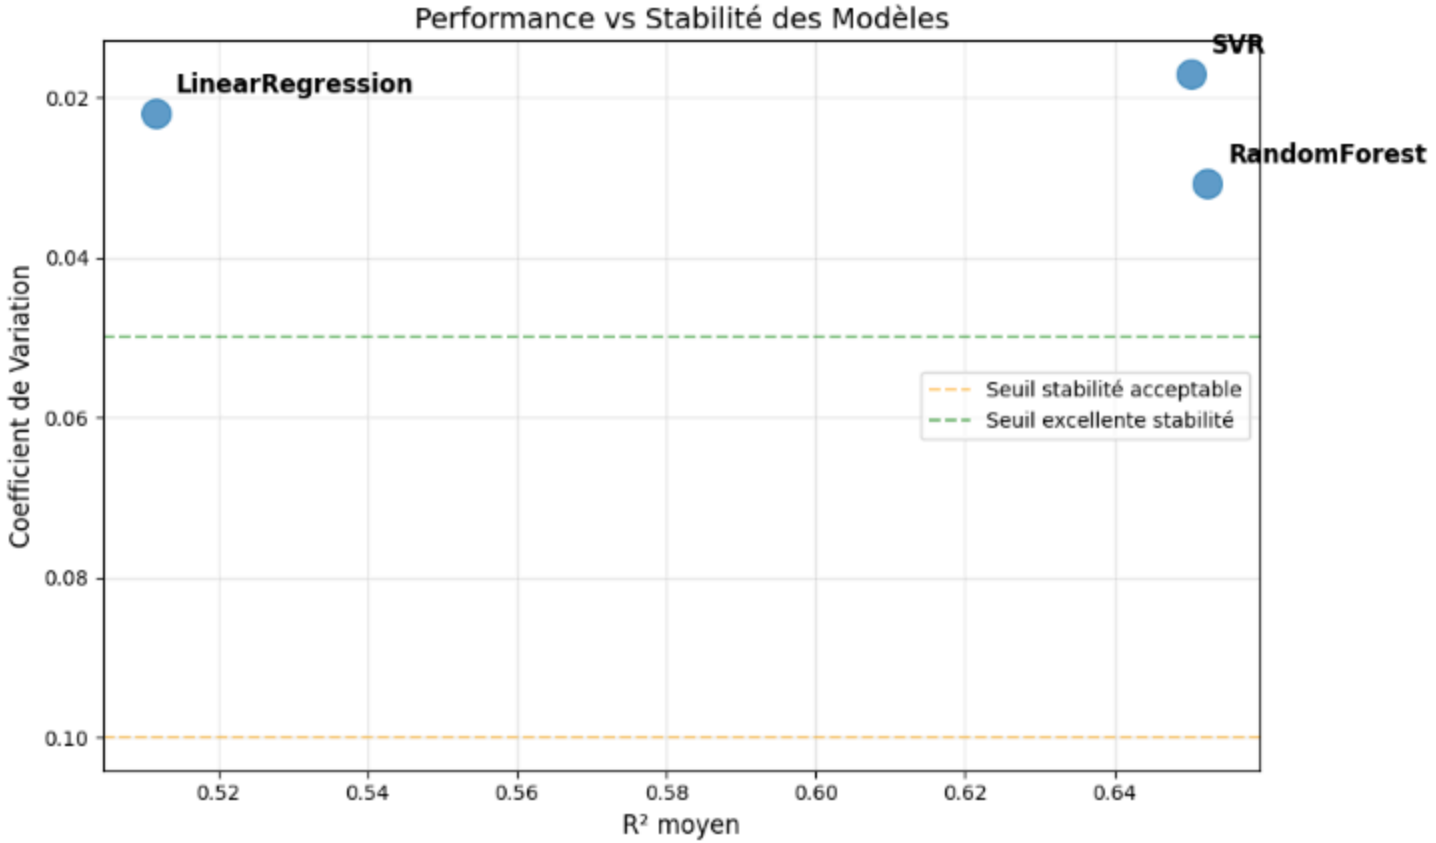
Démarche de Modélisation

Comparaison d'Algorithmes :

Modèle	R^2 Train (sans log)	R^2 Test (sans log)	R^2 Train (avec log)	R^2 Test (avec log)
Dummy	-0.00	-0.00	-0.00	-0.00
Linear Regression	0.72	0.58	0.66	0.51
Random Forest	**0.95**	**0.62**	**0.95**	**0.652**
SVR	-0.15	-0.17	0.76	0.650

Utopios® Tous droits réservés

Comparaison d'Algorithmes



Utopios® Tous droits réservés

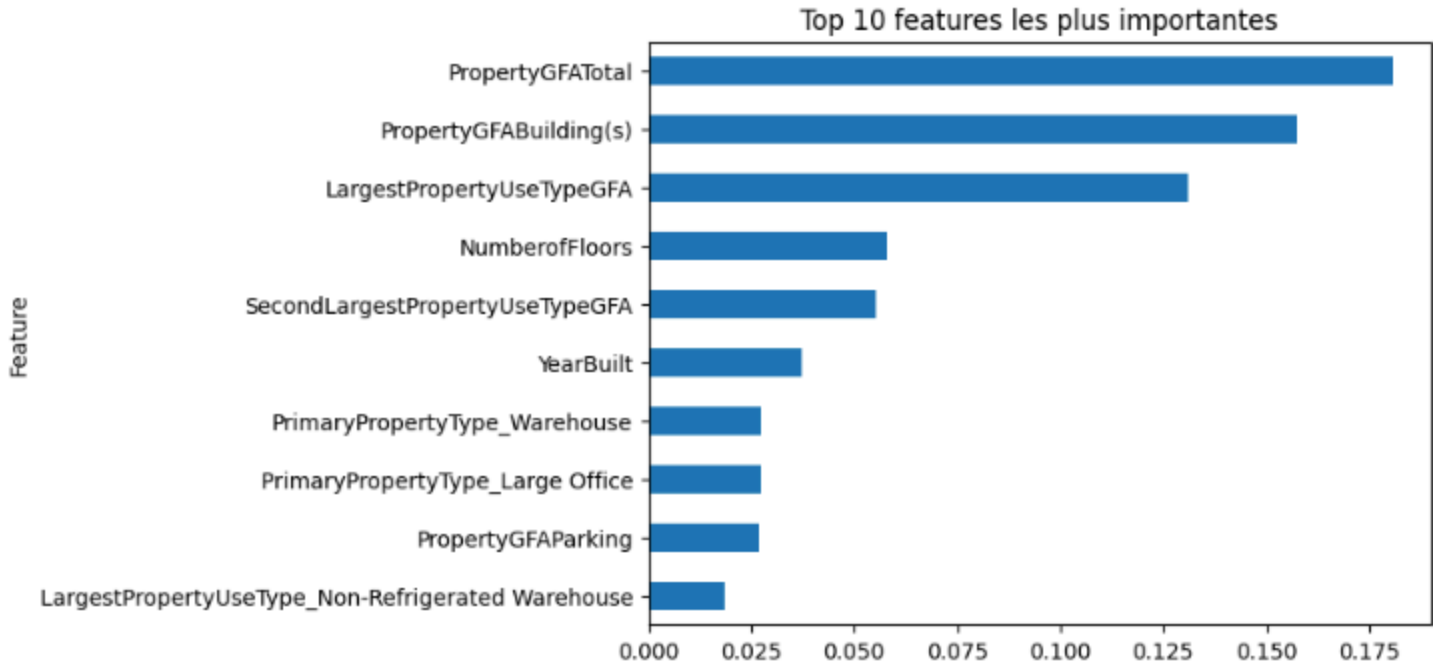
Analyse comparative :

Bien que le modèle SVR présente une meilleure stabilité, nous retenons le **RandomForest** pour la suite de l'analyse pour les raisons suivantes :

- **Performance supérieure** : Le RandomForest affiche un R^2 plus élevé que le SVR
- **Stabilité acceptable** : Le coefficient de variation du RandomForest reste dans une plage acceptable, garantissant une fiabilité suffisante
- **Interprétabilité** : Le RandomForest offre des feature importance plus riches que le SVR

Utopios® Tous droits réservés

Influence des Features sur le Modèle

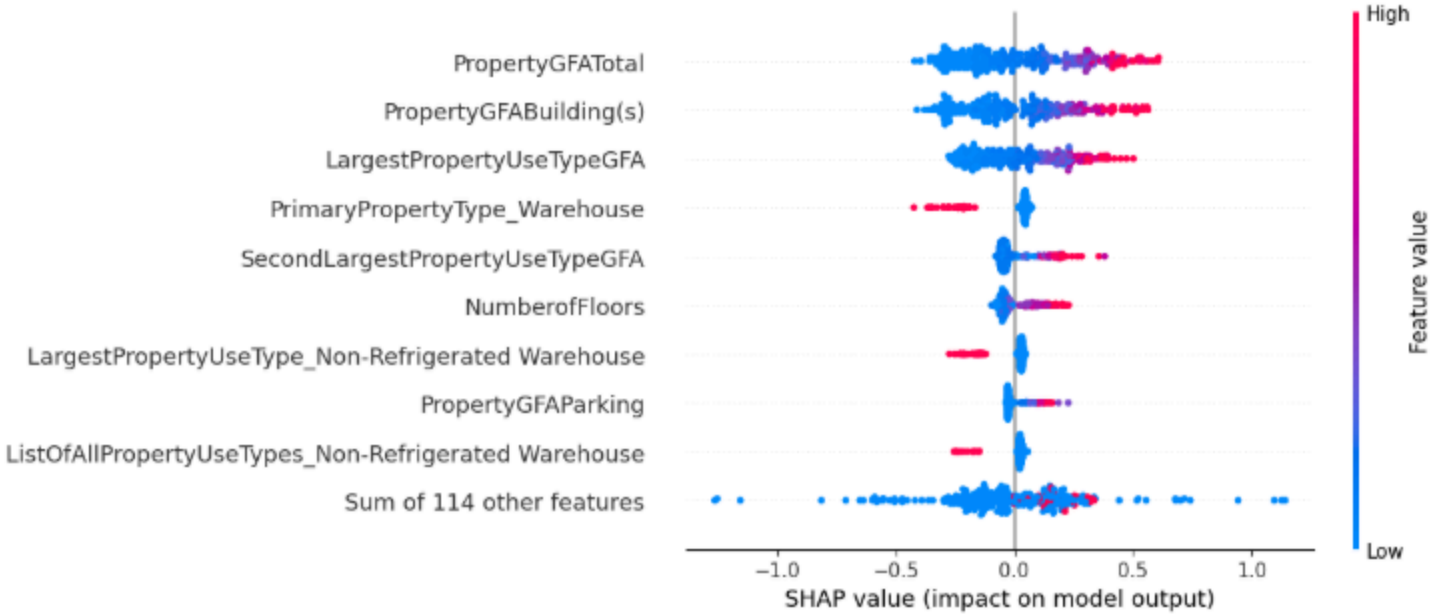


Utopios® Tous droits réservés

Analyse SHAP

Beeswarm Plot : Vue d'ensemble sur toutes les prédictions

- Confirmation : variables de surface dominent



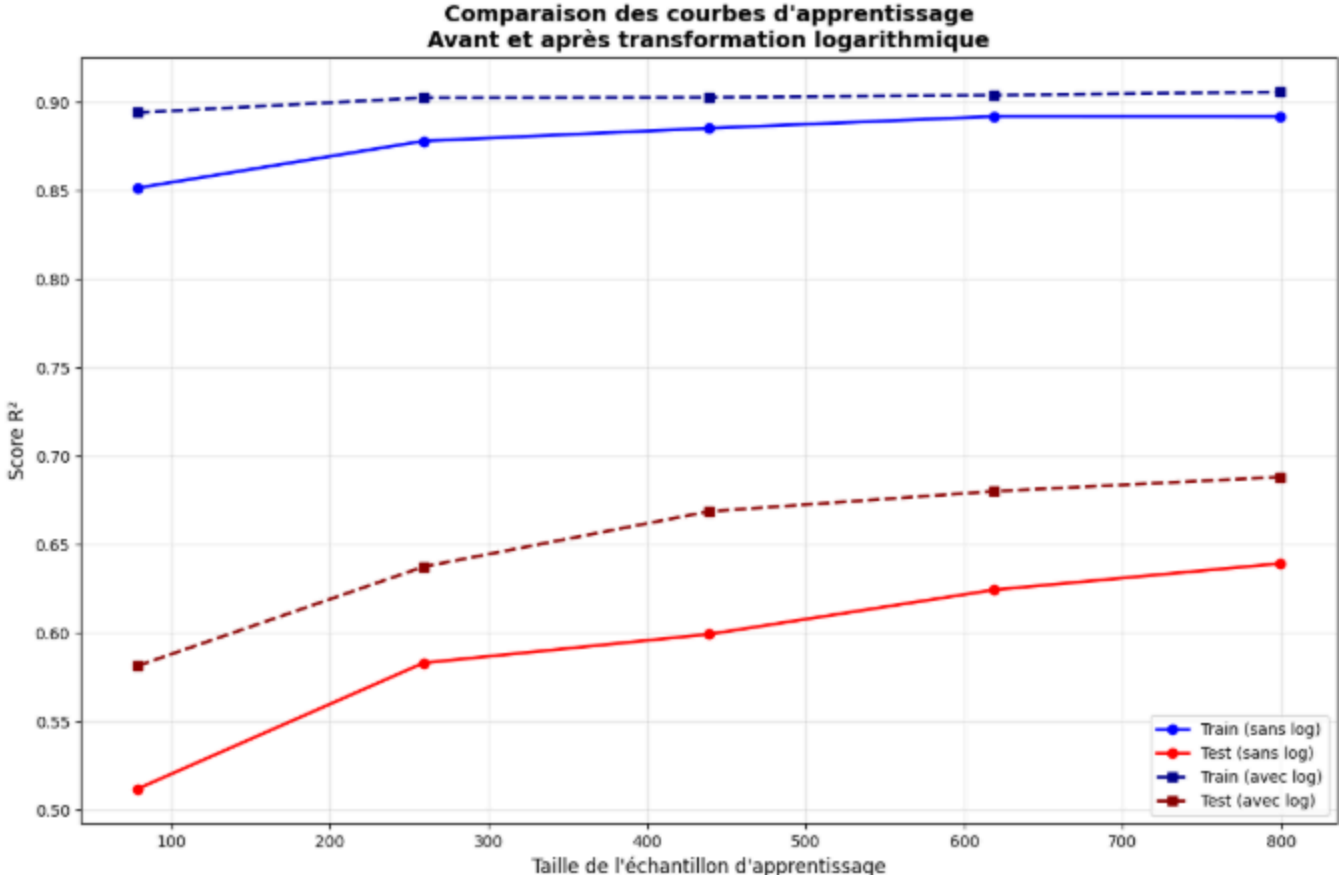
Utopios® Tous droits réservés

Conclusions

- **Cohérence du modèle** : Les variables de surface dominent logiquement les prédictions de consommation énergétique
- **Variabilité importante** : Même à surface égale, les consommations peuvent varier significativement (efficacité, usage, isolation...)
- **Validation** : Les résultats SHAP confirment l'importance des variables identifiées par le Random Forest

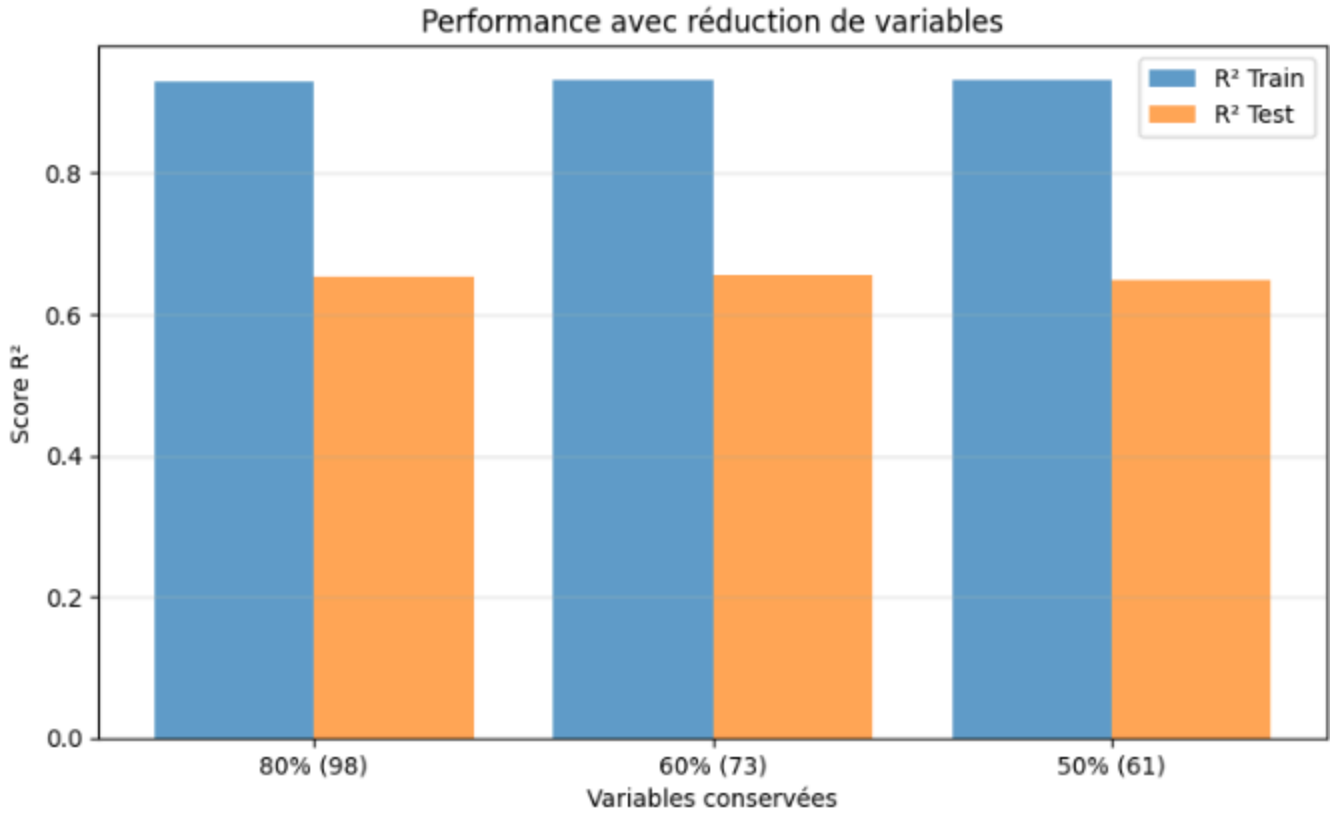
Utopios® Tous droits réservés

Courbes d'Apprentissage



Utopios® Tous droits réservés

Réduction des variables



Utopios® Tous droits réservés

Réduction des variables

Maintien des performances : Même en ne conservant que 50% des variables les plus importantes, le modèle maintient des performances très satisfaisantes, avec une dégradation minimale du score R^2. Cette stabilité démontre que de nombreuses variables du dataset ont un impact minime sur la prédiction.

Utopios® Tous droits réservés

Améliorations Possibles

1. **Engineering des features** :
   - Ratio surface/étages
   - Interaction entre type et surface
2. **Algorithmes avancés** :
   - XGBoost, LightGBM pour performances supérieures

Utopios® Tous droits réservés

Déploiement

- Modèle simplifié avec 60% ou 50% des variables les plus importantes
- Pipeline automatisé de préprocessing
- Monitoring des performances en production

Utopios® Tous droits réservés